

Opisne in številske napovedne spremenljivke

Opisna napovedna spremenljivka z dvema vrednostma

Opisna napovedna spremenljivka ima **dve vrednosti** - naredimo eno umetno spremenljivko

$$w_{1i} = \begin{cases} 0, & x_i = a_1 \\ 1, & x_i = a_2 \end{cases} \quad \text{referenčna vrednost/skupina}$$

Model

$$y_i = \beta_0 + \beta_1 w_{1i} + \varepsilon_i$$

Pričakovana vrednost y_i :

$$\mathbb{E}(y_i) = \begin{cases} \beta_0, & x_i = a_1 \\ \beta_0 + \beta_1, & x_i = a_2 \end{cases}$$

Opisne in številske napovedne spremenljivke

Opisna napovedna spremenljivka z dvema vrednostma

Pomen parametrov:

- β_0 je povprečje y za referenčno vrednost $x = a_1$, μ_{a_1}
- β_1 je razlika $\mu_{a_2} - \mu_{a_1}$

Testiramo ničelni domnevi

$$H_0 : \beta_0 = \mu_{a_1} = \beta$$

$$H_0 : \beta_1 = \mu_{a_2} - \mu_{a_1} = \delta$$

Primer: zveza med FEV in Smoke

Opisne in številske napovedne spremenljivke

t-test za dva neodvisna vzorca, ponovitev

***t*-test za primerjavo dveh povprečij** (*t*-test za dva neodvisna vzorca)

Predpostavke:

- imamo dva neodvisna vzorca
- analiziramo slučajno spremenljivko y , ki je v prvi populaciji porazdeljena $N(\mu_1, \sigma^2)$, v drugi populaciji pa $N(\mu_2, \sigma^2)$
- varianci obeh normalnih porazdelitev sta enaki

Zanima nas, ali sta povprečni vrednosti spremenljivke y v obeh populacijah enaki.

Opisne in številske napovedne spremenljivke

t-test za dva neodvisna vzorca

Testiramo ničelno domnevo:

$$H_0 : \mu_1 = \mu_2 \quad \text{ali} \quad \delta = \mu_1 - \mu_2 = 0$$

$$H_1 : \mu_1 \neq \mu_2 \quad \text{ali} \quad \delta = \mu_1 - \mu_2 \neq 0$$

Testna statistika

$$t = \frac{\bar{x}_1 - \bar{x}_2 - \delta}{\sqrt{s_{sk}^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim t_{n_1 + n_2 - 2}$$

Primer: vpliv kajenja Smoke na povprečno FEV

Opisne in številske napovedne spremenljivke

Opisna napovedna spremenljivka z I vrednostmi

Opisna napovedna spremenljivka x ima I vrednosti (a_1, a_2, \dots, a_I) .

Taka spremenljivka podatke deli v I skupin.

V model vključimo $I - 1$ regresorjev z vrednostmi 0 in 1.

$$w_1 = \begin{cases} 0, & x_i = a_1 \\ 1, & x_i = a_2 \\ 0, & x_i = a_3 \\ \dots & \\ 0, & x_i = a_I \end{cases}$$

$$w_{I-1} = \begin{cases} 0, & x_i = a_1 \\ 0, & x_i = a_2 \\ 0, & x_i = a_3 \\ \dots & \\ 1, & x_i = a_I \end{cases}$$

Opisne in številske napovedne spremenljivke

Opisna napovedna spremenljivka z l vrednostmi

Model

$$y_i = \beta_0 + \beta_1 w_{1i} + \beta_2 w_{2i} + \dots + \beta_{l-1} w_{li} + \varepsilon_i,$$

Pomen parametrov:

- $\beta_0 = \mu_{a_1}$ povprečje odzivne spremenljivke pri referenčni vrednosti opisne napovedne spremenljivke a_1
- razlike med povprečji j -te skupine in referenčne skupine:

$$\beta_j = \mu_{a_j} - \mu_{a_1}, j = 1, \dots, l - 1$$

$$\mathbb{E}(y_i) = \begin{cases} \beta_0, & x_i = a_1 \\ \beta_0 + \beta_1, & x_i = a_2 \\ \dots & \\ \beta_0 + \beta_{l-1}, & x_i = a_l. \end{cases}$$

Primer: FEV, spremenljivka Gender.Smoke

Opisne in številske napovedne spremenljivke

Dve opisni in ena številska napovedna spremenljivka

Varianta 1: Model brez interakcije opisnih in številske spremenljivke

Kakšna je zveza med FEV, Ht, Gender in Smoke?

Geometrijsko: štiri vzporedne premice (presečišča so različna, nakloni so enaki).

$$y_i = \beta_0 + \beta_1 \text{GenderM}_i + \beta_2 \text{SmokeDa}_i + \beta_3 \text{Ht}_i + \varepsilon_i$$

Opisne in številske napovedne spremenljivke

Dve opisni in ena številska napovedna spremenljivka

$$E(y_i) = \begin{cases} \beta_0 + \beta_3 \text{Ht}_i, & \text{Gender} = Z, \quad \text{Smoke} = Ne \\ (\beta_0 + \beta_1) + \beta_3 \text{Ht}_i, & \text{Gender} = M, \quad \text{Smoke} = Ne \\ (\beta_0 + \beta_2) + \beta_3 \text{Ht}_i, & \text{Gender} = Z, \quad \text{Smoke} = Da \\ (\beta_0 + \beta_1 + \beta_2) + \beta_3 \text{Ht}_i, & \text{Gender} = M, \quad \text{Smoke} = Da \end{cases}$$

Pomen parametrov:

- β_0 predstavlja povprečni FEV žensk nekadilk pri $\text{Ht}=0$
- β_1 je razlika povprečja FEV za moške in povprečja FEV za ženske nekadilke pri konstantni Ht na $[\text{Ht}_{\min}, \text{Ht}_{\max}]$
- β_2 je razlika povprečja FEV za kadilke/kadilce in povprečja FEV za nekadilke/nekadilce pri konstantni Ht na $[\text{Ht}_{\min}, \text{Ht}_{\max}]$
- β_3 je naklon vzporednih premic

Opisne in številske napovedne spremenljivke

Dve opisni in ena številska napovedna spremenljivka

Varianta 2: Model z interakcijo dveh opisnih in številske spremenljivke

V model vključimo Ht, Smoke in Gender ter **interakcijske člene**:

- **tri dvojne interakcije**: Gender : Smoke, Gender : Ht in Smoke : Ht
- **ena trojna interakcija**: Gender : Smoke : Ht

Predpostavimo, da je zveza med FEV in Ht različna pri kadilcih in nekadilcih, ta razlika je različna pri moških in pri ženskah.

Geometrijsko: **štiri različne premice** (presečišča so različna, nakloni so različni).